


Escuela Superior de Arte y Tecnología

Programación en Videojuegos

Artificial Intelligence (L5)

## Deep Learning



Realizado por:

José Manuel Gómez Castellana

Francisco Jiménez

<b>Introducción</b>	<b>3</b>
¿Que es el machine learning?	3
¿Que es el deep learning?	4
¿Diferencias entre el deep learning y el machine learning?	4
<b>Redes Neuronales</b>	<b>5</b>
¿Cómo se compone una neurona?	6
Capa de entrada:	7
Capa de Oculta:	8
Capa de Salida:	8
Redes Neuronales Clásicas	8
Redes Neuronales Convolucionales	8
Redes Neuronales Recurrentes	9
<b>¿Dónde y porqué surgió?</b>	<b>11</b>
Etapa Cibernética (entre los 40 y los 60)	11
Etapa de Conexionismo (entre 1980 y los 1995)	12
Etapa como Deep Learning (desde 2006)	13
<b>Aplicaciones actuales, beneficios.</b>	<b>14</b>
Ejemplos de uso actuales.	15
<b>El futuro del deep learning</b>	<b>19</b>
Bibliografía	21

## Introducción

### ¿Que es el machine learning?

El machine learning o aprendizaje automático podemos decir que es la forma mediante datos (“experiencias”) en la que enseñamos a nuestro algoritmo a cómo realizar la acción correcta basado en el “input” recibido, sin que esta acción se encuentre previamente programada, es decir el sistema aprende de forma autónoma a cómo tomar decisiones correctas.

Como por ejemplo podríamos programar a nuestro algoritmo para que se mueva en nuestro videojuego hacia distintas direcciones lo cual ya sería considerado IA, pero no machine learning ya que nuestro algoritmo por sí mismo no ha aprendido a moverse con los datos suministrados.

¿Como lo hace?, a través de las conocida redes neuronales, que mediante muchísimas interacciones y una gran cantidad de datos “input” permiten a nuestro algoritmo aprender de sus errores y tomar decisiones en base a su aprendizaje.

¿Como es el proceso de aprendizaje?, se realiza mediante la construcción de un modelo con una gran cantidad de datos, por ejemplo si tenemos la imagen de un ordenador, pues se extraen las características que conforman un ordenador de los datos antes mencionado, tras cada iteración nuestro algoritmo aprenderá las características de un ordenador y mejorará su rendimiento.

### ¿Que es el deep learning?

El deep learning lleva a cabo el proceso de machine learning pero usando una red neuronal artificial, que se compone de un número de niveles jerárquicos.

En el nivel inicial de nuestra jerarquía la red aprende algo simple, luego envía esta información al siguiente nivel “capa”, este nivel toma esta información sencilla y la combina, componiendo una información un poco más compleja y así sucesivamente hasta n capas que añadamos.

### ¿Diferencias entre el deep learning y el machine learning?

La principal diferencia es que en el machine learning seremos nosotros quienes extraigan de los datos las características que serán utilizadas como “input” de nuestros datos y que en

Alumnos: José Manuel Gómez Castellana y Francisco Jiménez

el deep learning ya nuestro modelo lo hará por nosotros extrayendo estas características por si mismo de los datos y pasandolo a las siguientes capas.





Figure 1: Machine Learning VS Deep Learning

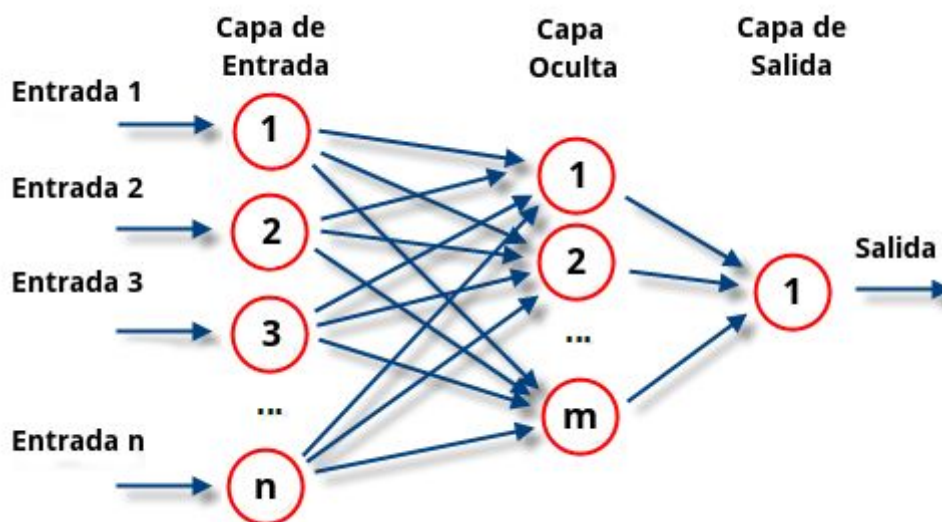
Haciéndolo mediante redes neuronales gigantescas, por ejemplo si hablamos de una imagen en este caso habrá una red neuronal por cada pixel, la cual irá uniendo con el resultado de otra entradas generando patrones, que permiten identificar un dato o en nuestro caso el contenido de una imagen.



## Redes Neuronales

Las redes neuronales artificiales son un modelo computacional que intenta simular el comportamiento de las neuronas humanas, consiste en un conjunto de neuronas artificiales conectadas entre sí para transmitir señales, la información de entrada pasa de capa a capa hasta llegar a finalmente a una salida con un resultado.

Cada neurona está conectada a otra a través de unos enlaces, en estos enlaces se le dará el valor de salida de la neurona anterior, el cual es multiplicado por un peso, estos pesos pueden incrementar el resultado o inhibir un estado de activación, también existe una función limitadora que modifica el valor del resultado llamada función activadora.



## ¿Cómo se compone una neurona?

**Entradas:** Son el Input o los datos que ingresan a nuestro sistema podrían ser imágenes números etc, que irían de  $a_1$  a  $a_n$ , las cuales serán multiplicada por cada uno de los pesos.

**Pesos:** Se encargará de regular la importancia de una entrada, para que sea mayor o menor, existiendo un peso por cada entrada.


**Bias:** Añade un desfase o offset para nuestro peso.

**Función de activación:** Permitirá no aplicar una no linealidad en nuestro sistema y devolverá una salida a partir de una entrada en un rango determinado de  $(0,1)$  o  $(-1,1)$ , existe distinta funciones de activación como lo son:

- Sigmoidal
- Hiperbólica Tangente
- Relu
- Leaky Relu
- Softmax

Fórmula de una neurona:

$$\text{Salidas} = \text{activación}(a_1 * w_1 + a_2 * w_2 + \dots + a_n * w_n + \text{bias})$$



## Capa de entrada:

Esta capa es la que contiene las entradas de nuestro sistema, algunos las llaman capas expuestas o visible, no es una capa que contenga neuronas clásicas o pesos simplemente da entrada a los datos que pasan a nuestro sistema y pasan a la siguiente capa.

## Capa de Oculta:

Las capas ocultas se llaman así, porque no se puede entrar directamente en contacto con ellas, si no que tiene que ser a través de las capa de entrada, este tipo de capas pueden contener miles de unidades de cálculo neuronal.

## Capa de Salida:

La capa de salida es la encargada de expedir las salidas correspondientes a las entrenadas. Este tipo de capas son decisivas en el funcionamiento del sistema y la magia de las mismas yacen en las activaciones que emplean, dichas activaciones deben adecuarse al problema que enfrentamos.

## Redes Neuronales Clásicas

Son las primeras redes neuronales también conocidas como perceptrones, que en su momento permitían predecir y clasificar, suelen estar compuestas por una o dos capas ocultas.

## Redes Neuronales Convolucionales

Son un tipo de redes neuronales artificiales diseñadas para funcionar de forma muy similar a las neuronas de la corteza visual primaria de un cerebro humano. Estas han resultado ser ampliamente eficaces en tareas fundamentales de la visión artificial como la clasificación y la segmentación de imágenes.

Dichas redes están formadas por múltiples capas de filtros convolucionales de una o más dimensiones, tras las cuales se insertan funciones no lineales de activación. Por ejemplo, en el caso de una clasificación clásica mediante una red convolucional, es



1. Extracción de características: Esta es la fase inicial y está compuesta principalmente por neuronas convolucionales que asemejan su procesamiento al de la corteza visual humana. Cuanto más se avanza a través del número de capas convolucionales menos reaccionan estas ante la variación de los datos de entrada y mayor es la abstracción alcanzada por las mismas para reconocer formas más complejas.

2. Clasificación: Se basan en la utilización de capas “Densas” formadas por neuronas convencionales, similares a las utilizadas por los modelos de tipo “perceptron”.

## Redes Neuronales Recurrentes

Una red neuronal recurrente no tiene una estructura de capas definida, si no que permiten conexiones arbitrarias entre las neuronas incluso pudiendo crear ciclos con esto se consigue crear la temporalidad permitiendo que la red tenga memoria.

Especialmente útil para analizar textos o videos, de esta forma nuestro algoritmo puede tener una relación de lo que sucede, por ejemplo nuestro algoritmo puede leer un texto y en base a un contexto responder a una acción, o en un vídeo por ejemplo teniendo la información de frames anteriores nuestro algoritmo podrá predecir lo que pasará al cabo de un par de segundos.

Básicamente las redes neuronales recurrentes permiten a nuestro algoritmo tener memoria de datos anteriores y usarlos en su análisis actual para poder responder con una mayor certeza.

Tipos de redes neuronales recurrentes:

Redes recurrentes Simples - SRN: Son la arquitectura base desde donde se han implementado el resto de tipos, permite la retroalimentación lo que consigue crear la temporalidad, permitiendo así que la red tenga memoria.

Redes GRU (Gated recurrent unit): Están compuestos por unidades GRU, la unidad GRU contiene puertas que controlan el modo en el que fluye la información dentro y fuera de la unidad, permitiendo así decidir qué es importante recordar y que debe olvidar, estas unidades se irán entrenando a medida de que vayamos entrenando nuestros modelos.



### Redes LSTM (Long Short Term Memory):

La unidad de memoria LSTM contiene tres puertas que controlan el modo en que la información fluye dentro o fuera de la unidad.

- Puerta de entrada controla cuando la información nueva puede entrar en la memoria.
- Puerta del olvido controla cuando se olvida una parte de la información, lo que permite a la celda discriminar entre datos importantes y superfluos, dejando así sitio para nuevos datos.
- Puerta de salida controla cuando se utiliza en el resultado de los recuerdos almacenados en la celda.

La celda dispone de un mecanismo de optimización de las ponderaciones basado en el error de salida de la red resultante, que controla cada puerta.

Estas redes se utilizan para compresión de textos de lenguajes naturales, reconocimiento de escritura a mano, reconocimiento de voz, reconocimiento de gestos, captura de imágenes.

## ¿Dónde y por qué surgió?

Para situarnos desde cuándo se empezó a hablar de Deep Learning, debemos incluso retroceder hasta los años 40 del siglo pasado. Las razones por las que el Deep Learning parece algo tan reciente es porque, a lo largo de su historia, ha vivido etapas complicadas en cuanto a popularidad. Además, el haber sido rebautizado varias veces ha dificultado su seguimiento. Solo en los últimos años se le ha denominado con el nombre de "Deep Learning".

Para entender el origen del Deep Learning, podemos concretar cronológicamente tres etapas principales:

### Etapas Cibernética (entre los 40 y los 60)

Un neurofisiólogo, Warren McCulloch , y un matemático, Walter Pitts, co-escribieron un artículo sobre cómo podrían funcionar las neuronas humanas. Para ilustrar la teoría, modelaron una red neuronal con circuitos eléctricos. Su modelo, típicamente llamado neuronas McCulloch-Pitts, sigue siendo el estándar hoy en día (aunque ha evolucionado a lo largo de los años).

En 1950, Turing propuso tal máquina, incluso insinuando algoritmos genéticos, en su artículo "Computing Machinery and Intelligence". En él, creó lo que se ha llamado The Turing Test – aunque él mismo lo llamó The Imitation Game – para determinar si una computadora puede "pensar".

En su forma más simple, la prueba requiere que una máquina lleve a cabo una conversación a través de texto con un ser humano. Si después de cinco minutos el humano está convencido de que está hablando con otro humano, se dice que la máquina ha pasado. Tomaría 60 años para que cualquier máquina lo hiciera, aunque muchos todavía debaten la validez de los resultados.

Arthur Samuel inventó el aprendizaje automático y acuñó la frase "aprendizaje automático" en 1952. Es venerado como el padre del aprendizaje automático.

Al unirse al Laboratorio Poughkeepsie en IBM, Arthur Samuel pasaría a crear los primeros programas de aprendizaje por computadora. Los programas fueron construidos para jugar el

juego de las damas. El programa de Arthur Samuel era único en el sentido de que cada vez que se jugaban las damas, la computadora siempre mejoraba, corrigiendo sus errores y encontrando mejores maneras de ganar a partir de esos datos. Este aprendizaje automático sería uno de los primeros ejemplos de aprendizaje automático.

Rosenblatt, un psicólogo, presentó un artículo titulado "The Perceptron: A Perceiving and Recognizing Automaton" al Laboratorio Aeronáutico de Cornell en 1957.

Declaró que "construiría un sistema electrónico o electromecánico que aprendería a reconocer similitudes o identidades entre patrones de información óptica, eléctrica o tonal, de una manera que puede ser muy análoga a los procesos perceptivos de un cerebro biológico".

Su idea era más hardware que software o algoritmo, pero plantó las semillas del aprendizaje de abajo hacia arriba, y es ampliamente reconocido como la base de las redes neuronales profundas (DNN).

El matemático Ivakhnenko y sus asociados, incluyendo la otra vez, Ilya Lapa crearon las primeras redes de deep learning en funcionamiento en 1965, aplicando lo que habían sido sólo teorías e ideas hasta ese momento.

Ivakhnenko desarrolló el Método de Grupo de Manejo de Datos (GMDH) – definido como una "familia de algoritmos inductivos para el modelado matemático basado en computadora de conjuntos de datos multiparamétricos que cuenta con una optimización estructural y paramétrica totalmente automática de los modelos" – y lo aplicó a las redes neuronales.

Sólo por esa razón, muchos consideran a Ivakhnenko el padre del deep learning moderno. Sus algoritmos de aprendizaje utilizaban perceptrones multicapa de avance profundo utilizando métodos estadísticos en cada capa para encontrar las mejores características y re enviarlas a través del sistema.

Usando GMDH, Ivakhnenko fue capaz de crear una red profunda de 8 capas en 1971, y demostró con éxito el proceso de aprendizaje en un sistema de identificación informática llamado Alpha.

## Etapa de Conexionismo (entre 1980 y los 1995)

Fue en esta época en la que surgió el concepto de backpropagation con la llegada de Rumelhart et al (1986). Estas herramientas se emplean de forma masiva en el entrenamiento de redes neuronales. Todo ello para calcular los pesos de las neuronas correspondientes a las distintas capas de las mismas.

En 1982, Hopfield creó y popularizó el sistema que ahora lleva su nombre.

Hopfield Networks es una red neuronal recurrente que sirve como un sistema de memoria direccionable por contenido, y siguen siendo una herramienta de implementación popular para el deep learning en el siglo XXI.

En 1986 un artículo titulado "Representaciones Aprendizaje por errores de propagación posterior", Rumelhart, Hinton y Williams describieron con mayor detalle el proceso de retropropagación.

Mostraron cómo podría mejorar enormemente las redes neuronales existentes para muchas tareas como el reconocimiento de formas, la predicción de palabras y más.

A pesar de algunos contratiempos después de ese éxito inicial, Hinton mantuvo su investigación durante el segundo invierno de IA para alcanzar nuevos niveles de éxito y aclamación. Es considerado por muchos en el campo como el padrino del deep learning.

En 1989 Watkins publicó su tesis doctoral –"Aprender de recompensas retrasadas"– en 1989. En él, introdujo el concepto de Q-learning, que mejora en gran medida la practicidad y viabilidad del aprendizaje de refuerzo en las máquinas.

Este nuevo algoritmo sugirió que era posible aprender un control óptimo directamente sin modelar las probabilidades de transición o las recompensas esperadas del Proceso de Decisión de Markov.

En 1995 Las máquinas vectoriales de soporte , o SVM , han existido desde la década de 1960, ajustados y refinados por muchos a lo largo de las décadas.

El modelo estándar actual fue diseñado por Cortes y Vapnik en 1993 y presentado en 1995. Una SVM es básicamente un sistema para reconocer y mapear datos similares, y se puede utilizar en la categorización de texto, el reconocimiento de caracteres escritos a mano y la clasificación de imágenes en relación con el aprendizaje automático y el deep learning.

## Etapa como Deep Learning (desde 2006)

Debido a que históricamente algunos de los primeros modelos pretendían emular el aprendizaje biológico, el término Artificial Neural Networks (ANN) se ha ido ligando cada vez más al Deep Learning.

Sin embargo, a pesar de que los modelos de Deep Learning están inspirados en el cerebro biológico, no están diseñados para ser una representación realista. Hoy en día, el Deep Learning ya no se encuentra tan relacionado con la perspectiva neurocientífica.

Ahora, este estudio trabaja más bien con el tipo de aprendizaje que propone a través de múltiples niveles de composición. Hay que pensar que esta disciplina busca dar una solución al hecho de que hay máquinas que sobrepasan a nuestras mentes en tareas formales o abstractas.

## Aplicaciones actuales, beneficios.

Con la aparición de nuevos avances se ha logrado incluso realizar numerosas aplicaciones prácticas. Hasta tal punto que se han introducido en la vida cotidiana de millones de usuarios.

Ejemplos claros son el procesamiento y reconocimiento de imágenes para la identificación de objetos, rostros y/o expresiones faciales. Estos se utilizan para la autenticación de identidades o para realizar diagnósticos de enfermedades. Todo ello llevado a cabo por medio de análisis comparativos automatizados con respecto a imágenes previas.

Otro ejemplo de la aplicación del aprendizaje profundo se basa en el reconocimiento de voz. Con la comprensión del lenguaje que hoy se utiliza en los asistentes personales inteligentes con Siri, Cortana y Google Assistant.


Su aplicación además se puede ver actualmente en: el desarrollo de vehículos autónomos, sistemas para gestionar su movilidad y el tráfico urbano, el desarrollo de nuevos dispositivos para diagnósticos médicos remotos o el diseño de nuevos materiales.

Pero también en el desarrollo de sistemas avanzados de traducción automática multilingüaje. El futuro está más cerca de lo que pensamos, y en muchos casos, estos avances se basan en el uso de métodos y tecnologías del aprendizaje profundo.

Ejemplos de uso actuales.

## 2014 – DeepFace

Desarrollado y lanzado al mundo en 2014, el sistema de deep learning del gigante de las redes sociales, apodado DeepFace, utiliza redes neuronales para identificar rostros con una precisión del 97,35%.



Eso es una mejora del 27% con respecto a los esfuerzos anteriores, y una cifra que rivaliza con la de los seres humanos (que se informa que es 97,5%).

## 2014 – Generative Adversarial Networks (GAN)

Introducido en 2014 por un equipo de investigadores dirigido por Ian Goodfellow, una autoridad nada menos que el propio Yann LeCun tenía esto que decir sobre los GANs:

Las redes adversarias generativas permiten modelos para abordar el aprendizaje no supervisado, que es más o menos el objetivo final en la comunidad de inteligencia artificial.

Esencialmente, un GAN utiliza dos redes de la competencia: la primera toma datos e intenta crear muestras indistinguibles, mientras que la segunda recibe los datos y las muestras creadas, y debe determinar si cada punto de datos es genuino o generado.

Aprendiendo simultáneamente, las redes compiten unas contra otras y se empujan unas a otras para ser "más inteligentes" más rápido.


## Colorización Automática de imágenes en blanco y negro

La colorización de imágenes es una tarea tradicionalmente hecha con esfuerzo humano, porque se requiere de un criterio visual muy alto.

Sin embargo, una de las aplicaciones del deep learning consiste en la capacidad de identificar objetos y su contexto dentro de una fotografía en blanco y negro, para colorearla.

Esta imagen es un set de fotografías originalmente entregadas en blanco y negro, y que fueron coloreadas con una exactitud impresionante.






El sistema utilizado se basó en ImageNET, una inmensa base de datos de imágenes clasificada de acuerdo a la jerarquía de WordNet, otra base de datos de palabras.

## Traducción automática

Esta es una tarea donde algunas palabras dadas, frases u oraciones en un idioma, se traducen automáticamente a otro.

La traducción automática se ha estado desarrollando desde hace años, pero el deep learning está alcanzando resultados óptimos en dos áreas:

- Traducción automática de texto.
- Traducción automática de imágenes.



En el caso del texto, el algoritmo puede aprender la dependencia entre palabras y asignarlas a un nuevo idioma.

Como te imaginarás, las redes neuronales se usan para identificar imágenes que tienen caracteres y dónde se encuentran las letras en la escena.


Una vez identificados estos caracteres, son interpretados y convertidos en texto, para luego ser traducidos. Usualmente a este proceso se le llama traducción visual instantánea.

## Clasificación de objetos y detección en Fotografías

En algunas pruebas como las que mostramos a continuación, se han alcanzado resultados impresionantes usando extensas redes neuronales.

Probablemente hayas oído en las noticias hace algún tiempo que China tiene cámaras de seguridad que funcionan con inteligencia artificial, para detectar a los ciudadanos al instante.

Una variación más compleja de este sistema de detección de objetos implica la detección de varios objetos en la misma escena.



Como puedes ver en esta imagen, este sistema puede no sólo detectar un objeto, sino darte información extra de sus características.

Esperamos haber aportado con ejemplos reales, una mejor idea de cómo el Deep Learning se está aplicando en la actualidad.

## El futuro del deep learning

Mediante el Deep Learning se propone que las máquinas sean cada vez más capaces de entender el mundo. Todo ello, a través de una jerarquía y una fragmentación de conceptos. Con los últimos avances en neurociencias, el incremento en las capacidades de procesamiento de los sistemas de cómputo, el big data y la mejora de servicios en línea tales como el Cloud Computing, se ha logrado acelerar el desarrollo de sistemas capaces de imitar aspectos de cómo el ser humano piensa y actúa.

En el campo de los videojuegos hay muchas cosas que se podrían explorar, cómo:

### Algoritmos jugando como PNJ

En este momento, tus oponentes en un videojuego son PNJ pre-guionizados (personajes no jugables), pero un PNJ basado en aprendizaje automático podría permitirte jugar contra enemigos menos predecibles. Estos enemigos también podrían ajustar su nivel de dificultad. A medida que aprendes a jugar el juego, tus enemigos podrían ser más inteligentes y responder de maneras únicas basadas en tus acciones dentro del juego.

Las empresas ya están trabajando en las primeras aplicaciones de los PNJ basados en el aprendizaje automático. Sus PNJ aprenden movimientos y acciones dinámicas, y el uso de las acciones de los jugadores humanos como los datos de entrenamiento significa que el algoritmo entrena cuatro veces más rápido que el entrenamiento de refuerzo solo.

Los PNJ enseñables son una mejora no trivial para el desarrollo de juegos. Actualmente, los estudios de juegos pasan cientos de horas de trabajo scripting NPCs. Sin los PNJ de codificación rígida se podría reducir significativamente el ciclo de desarrollo de un juego. De semanas a horas.

### Modelado de sistemas complejos

La fuerza de un algoritmo de aprendizaje automático es su capacidad para modelar sistemas complejos. Los desarrolladores de videojuegos están constantemente tratando de conseguir que los juegos sean más inmersivos y realistas. Por supuesto, modelar el mundo real es increíblemente difícil, pero un algoritmo de aprendizaje automático podría ayudar a

predecir los efectos posteriores de las acciones de un jugador o incluso modelar cosas que el jugador no puede controlar, como el clima.

Un ejemplo actual de modelado complejo actualmente en producción es el modo de equipo definitivo de la FIFA. A medida que seleccionas tu equipo de jugadores estrella, FIFA calcula una puntuación de química del equipo en función de cuánto podrían llevarse bien las personalidades de tu equipo, o no. Durante los partidos, la moral del equipo puede bajar si estás perdiendo o cometiendo pequeños errores. También puede aumentar cuando la multitud aplaude y estás jugando bien. Los cambios en la moral afectan las habilidades de los jugadores, en el juego. Más errores vienen cuando la moral es baja, y los tiros de habilidad y los descansos de la suerte ocurren con más frecuencia cuando el equipo está jugando bien juntos.

## Interacciones más realistas

Otro desafío importante en la construcción de un mundo virtual realista es cómo los jugadores interactúan con los PNJ amistosos. En muchos juegos, es necesario hablar con personajes con guiones con el fin de completar sus objetivos. Sin embargo, estas conversaciones tienen un alcance limitado y, por lo general, siguen las indicaciones en pantalla.

El uso del procesamiento de lenguaje natural podría permitirle hablar en voz alta con los personajes del juego y obtener respuestas reales, al igual que hablar con Siri, Alexa o Google Assistant. Además, los juegos que incorporan la opción de realidad virtual o la creación de imágenes del jugador podrían permitir que los algoritmos de visión por ordenador detecte el lenguaje corporal y las intenciones, mejorando aún más la experiencia de interactuar con los PNJ.

Todavía hay grandes desafíos a los que se enfrentan las aplicaciones de aprendizaje automático en los juegos. Uno de los principales desafíos es la falta de datos de los que aprender. Estos algoritmos modelan sistemas y acciones complejas, y no tenemos buenos datos históricos sobre estas interacciones complicadas. Además, los algoritmos de aprendizaje automático desarrollados para la industria del juego deben ser infalibles. No pueden romper el juego ni la experiencia del jugador. Esto significa que los algoritmos deben ser correctos, pero también deben ser rápidos y sin problemas desde la perspectiva del jugador. Cualquier cosa que ralentice o rompa el juego saca al jugador de la inmersión en el mundo que el juego ha creado.

Dicho esto, la mayoría de los principales estudios de desarrollo de juegos tienen equipos que investigan, refinan y aplican la IA en sus juegos. Este es un desafío en el que muchas empresas están trabajando porque presenta una oportunidad tan emocionante para expandir los videojuegos a nuevos horizontes, dando a los jugadores experiencias aún más realistas y contenido más jugable.

## Bibliografía

Calvo, D., 2020. Red Neuronal Recurrente - RNN - Diego Calvo. [online] Diego Calvo. Available at:

<<http://www.diegocalvo.es/red-neuronal-recurrente/>>

[Accessed 23 March 2020].

Fuentes Jiménez, D., 2020. Deep Learning E Inteligencia Artificial Con Keras/Tensorflow. [online] Udemy. Available at:

<<https://www.udemy.com/course/curso-de-deep-learning-con-kerastensorflow-en-python/>>

[Accessed 23 March 2020].

EL ORIGEN DE DEEP LEARNING at:

< <https://master-deeplearning.com/origen-deep-learning/>>

[Accessed 01 May 2020].

A History of Machine Learning and Deep Learning at:

<<https://www.import.io/post/history-of-deep-learning/>>

[Accessed 01 May 2020].

Inteligencia artificial 4 aplicaciones at

<<https://ilifebelt.com/aplicaciones-del-deep-learning/2018/02/>>

[Accessed 01 May 2020].

6 ways machine learning will be in game development at

<<https://www.logikk.com/articles/machine-learning-in-game-development/>>

[Accessed 01 May 2020].